

GPU通讯技术



1. 简介

GPU在高性能计算和深度学习加速中扮演着非常重要的角色，GPU的强大的并行计算能力，大大提升了运算性能。随着运算数据量的不断攀升，GPU间需要大量的交换数据，GPU通信性能成为了非常重要的指标。NVIDIA推出的GPUDirect就是一组提升GPU通信性能的技术。但GPUDirect受限于PCI Express总线协议以及拓扑结构的一些限制，无法做到更高的带宽，为了解决这个问题，NVIDIA提出了NVLink总线协议。NVLink 实现了很大的进步，可以在单个服务器中支持八个 GPU，并且可提升性能，使之超越 PCIe。但是，要将深度学习性能提升到一个更高水平，将需要使用 GPU 架构，该架构在一台服务器上支持更多的 GPU 以及 GPU 之间的全带宽连接。NVIDIA NVSwitch 是首款节点交换架构，可支持单个服务器节点中 16 个全互联的 GPU，并可使全部 8 个 GPU 对分别以 300 GB/s 的惊人速度进行同时通信。

2. GPU Direct

GPU Direct优化主要包括加速与网络和存储设备的通信、GPU之间的Peer-to-Peer Transfers、GPU之间的Peer-to-Peer memory access、RDMA支持等。


2.1 shared memory

2010年6月最先引入的是GPUDirect Shared Memory 技术，支持GPU与第三方PCI Express设备通过共享的pin住的host memory实现共享内存访问从而加速通信。

Without GPUDirect

Same data copied three times:


1. GPU writes to pinned system1
2. CPU copies from system1 to system2
3. InfiniBand driver copies from system2



With GPUDirect


Data only copied twice

Sharing pinned system memory makes system-to-system copy unnecessary




2.2 p2p

2011年，GPUDirect增加了相同PCI Express root complex 下的GPU之间的Peer to Peer(P2P) Direct Access和Direct Transfers的支持。




2.3 RDMA

2013年，GPUDirect增加了RDMA支持，使得第三方PCI Express设备可以bypass CPU host memory 直接访问GPU。



3. NVLINK



依赖PCIe的gpu互连

随着开发人员在人工智能 (AI) 计算等应用领域中越来越依赖并行结构，各行各业中的多 GPU 和多 CPU 系统愈发普及。其中包括采用 PCIe 系统互联技术的 4 GPU 和 8 GPU 系统配置来解决非常复杂的重大难题。然而，在多 GPU 系统层面，PCIe 带宽逐渐成为瓶颈，这就需要更快速和更具扩展性的多处理器互联技术。

NVLink，是英伟达（NVIDIA）开发并推出的一种总线及其通信协议。NVLink采用点对点结构、串列传输。NVIDIA® NVLink™ 技术提供更高带宽与更多链路，并可提升多 GPU 和多 GPU/CPU 系统配置的可扩展性，因而可以解决这种互联问题。





nvlink-p100-diff-pairs-diagram.png（权限不足，图片迁移失败）

nvlink目前发展了两代

1		单条链路带宽	链路数	代表GPU
2	nvlink 1.0	双向 40GB/s	4	P100
3	nvlink 2.0	双向 50GB/s	6	V100


NVlink网络拓扑



在 DGX-1V 服务器中，混合立体网络拓扑使用 NVLink 连接 8 个 Tesla V100 加速器

4.0 NVSWITCH

NVLink 实现了很大的进步，可以在单个服务器中支持八个 GPU，并且可提升性能，使之超越 PCIe。但是，要将深度学习性能提升到一个更高水平，将需要使用 GPU 架构，该架构在一台服务器上支持更多的 GPU 以及 GPU 之间的全带宽连接。



NVIDIA NVSwitch 是首款节点交换架构，可支持单个服务器节点中 16 个全互联的 GPU，并可使全部 8 个 GPU 对分别以 300 GB/s 的惊人速度进行同时通信。




Figure-1: NVSwitch Topology Diagram - Two GPUs' connections shown for simplicity. All 16 GPUs connect to NVSwitch chips in the same way.

参考资料：

1. hotchips NVSwitch:



2.01_Nvidia_NVswitch_HotChips2018_DGX2NVS_Final.pdf (1MB)