

NCCL2介绍



NCCL2介绍

1. 通信方式


并行任务的通信一般可以分为P2P(Point-to-Point)通信和Collective通信。P2P通信模式只有一个发送者和一个接收者，实现起来比较简单。

第二种Collective通信包含多个发送者和多个接收者，一般的通信原语包括broadcast、gather、all-gather、scatter、reduce、all-reduce、reduce-scatter、all-to-all等。

简单介绍几个常用的操作：

(1) Reduce

从多个发送者接受数据，最后在一个节点上聚合。



(2) All-reduce

从多个发送者接受数据，最后在每一个节点聚合。




传统Collective通信假设通信节点组成的拓扑是一颗fat tree，通信效率最高。但实际通信的拓扑结构可能比较复杂，并不是一个fat tree。因此一般用基于环的通信方式。

基于环的通信将所有的通信节点通过首尾连接形成一个单向环，数据在环上依次传输。

以broadcast为例，假设有4个GPU，GPU0是发送者，将信息发送给剩下的GPU，按照环的方式依次传输，GPU0->GPU1->GPU2->GPU3，若数据量为N，带宽为B，通信节点为K，则整个传输时间为 $(K-1)N/B$ 。时间随着节点数线性增长，不是很高效。



将需要传输的数据分成S份，每次只传N/S的数据量，传输过程如下所示。



GPU1接收到GPU0的一份数据后，也接着传到环的下个节点，这样以此类推，最后花的时间为

$$S \cdot (N/S/B) + (K-2) \cdot (N/S/B) = N(S+K-2)/(SB)$$


当数据的份数S远大于节点数K时， $N(S+K-2)/(SB) \rightarrow N/B$ 。所以通信时间不随节点数的增加而增加，只和数据总量以及带宽有关。其它通信操作比如reduce、gather以此类推。

以GPU为通信节点的场景下，构建通信环：

单机4卡通过同一个PCIe switch挂载在一棵CPU的场景：



单机8卡通过同一个PCIe switch挂载在一棵CPU的场景：



PCIe: 是计算机总线PCI的一种，仅应用于内部互连。PCIe对用户可见的部分就是主板上大大小小的PCIe插槽。

PCIe switch: 相对于桥最大的一个本质区别就是同一个Bus内部的多个角色之间采用的是Switch交换而不是Bus。

InfiniBand: 是一个用于高性能计算的计算机网络通信标准，它具有极高的吞吐量和极低的延迟，用于计算机与计算机之间的数据互连。

2. NCCL

NCCL的全称是Nvidia Collective multi-GPU Communication Library。NCCL实现了多GPU和多节点的collective通信（all-gather、all-reduce、broadcast、reduce、reduce-scatter）。并且Nvidia做了很多优化，可以在PCIe、Nvlink、InfiniBand上实现较高的通信速度。

NCCL实现成CUDA C++ kernels，包含3种原语操作：Copy、Reduce、ReduceAndCopy。NCCL 1.0版本只支持单机多卡，卡之间通过PCIe、NVlink、GPU Direct P2P来通信。NCCL 2.0支持多机多卡，多机间通过Sockets (Ethernet)或者InfiniBand with GPU Direct RDMA通信。目前NCCL最新版本是2.3，并且已经在[github](#)开源。

****NVlink:** ** 英伟达（NVIDIA）开发并推出的一种总线及其通信协议。NVLink采用点对点结构、串行传输，用于CPU与GPU之间的连接。

****RDMA:** ** 计算机之间网络数据传输时降低CPU负载的高吞吐、低延时通信技术。

****GPU Direct:** ** GPU Direct是NVIDIA推出的一组提升GPU通信性能的技术。

****GPU Direct P2P:** ** 主要用于单机GPU间的高速通信，它使得GPU可以通过PCI Express直接访问目标GPU的显存，避免了通过拷贝到CPU host memory作为中转，大大降低了数据交换的延迟。

****GPU Direct RDMA:** ** 主要是指是计算机A的GPU可以直接访问计算机B的GPU内存。最终达到高带宽，低延迟和低CPU资源利用率的效果

单机内多卡通过PCIe以及CPU socket通信，多机通过InfiniBand通信。



在多机多卡内部，也要构成一个通信环



3. 参考文献

[1] <https://www.zhihu.com/question/63219175/answer/206697974>

[2] <https://developer.nvidia.com/nccl>

[3] <https://zh.wikipedia.org/wiki/InfiniBand>

[4] <https://github.com/NVIDIA/nvcc>