

昆仑一通讯库（BKCL）多机多卡支持

 本页面由边俊柯于2022/06/17迁移自wiki 陈庆澍空间

一、简介：

昆仑一通讯库（BKCL）已经支持了单机多卡的broadcast、reduce、all-reduce等接口，并且集成到paddle中支持单机多卡的训练。本文档主要介绍BKCL如何扩展支持多机多卡方案。

二、all reduce流程：

2.1 昆仑一单机多卡流程

昆仑一单机多卡all reduce通过将卡上数据拷贝到CPU上，进行累加，再拷贝到各个卡上来实现，具体步骤如下：

1. 用户在每张卡上调用all_reduce接口（可以通过bkcl_group接口在一个线程中依次调用每张卡的bkcl_all_reduce，或者每个线程调用各自卡的bkcl_all_reduce）
2. 每张卡都有一个对应的后台线程，后台线程接收bkcl_all_reduce的参数
3. 每张卡的后台线程将数据拷贝到cpu上，然后post其余各个卡的semaphore，告诉其他卡当前卡的数据已经在cpu上了
4. sem_timedwait在自己的卡上的信号量，直到其他卡的数据都已经ready；
5. 假设单机上总共有n个卡，每张卡负责1/n的数据的计算，计算完后，通过各个卡上另外的信号量通知其他卡计算完成
6. sem_timedwait在自己的卡上的另一个信号量，直到其他卡的计算都已经完成；
7. 将数据拷贝到各个卡上；
8. 通知主线程，当前all_reduce已经完成；

2.2 昆仑一多机多卡流程

在多机多卡的场景下，假设总共有m台机器，每台机器有n个卡，则具体步骤变为：

1. 用户在每张卡上调用all_reduce接口（可以通过bkcl_group接口在一个线程中依次调用每张卡的bkcl_all_reduce，或者每个线程调用各自卡的bkcl_all_reduce）
2. 每张卡都有一个对应的后台线程，后台线程接收bkcl_all_reduce的参数
3. 每张卡的后台线程将数据拷贝到cpu上，然后post其余各个卡的semaphore，告诉其他卡当前卡的数据已经在cpu上了
4. sem_timedwait在自己的卡上的信号量，直到其他卡的数据都已经ready；

5. 假设单机上总共有 n 个卡，每张卡负责 $1/n$ 的数据的计算，计算完后，通过各个卡上另外的信号量通知其他卡计算完成
6. `sem_timedwait`在自己的卡上的另一个信号量，直到其他卡的计算都已经完成；
7. 此时分两种情况：
 - a. 如果是单机多卡，跳到步骤八
 - b. 如果是多机多卡，
 - i. master卡（比如这台机器上rank最小的卡）将自己卡上的 $1/m$ 数据通过brpc依次发给其余 $m-1$ 台机器（异步rpc调用，在rpc内部会将数据拷贝到share_memory, 并且post 多机的信号量），其他卡`sem_timedwait`在自己计算多卡数据的semaphore上
 - ii. master卡`sem_timedwait`在自己多机的信号量上，直到收到其他机器的数据；
 - iii. `sem_post`通知本机的其他卡，开始进行计算
 - iv. 本机所有卡的线程开始计算，算完后`sem_post` master卡的计算信号；除master卡外，都等待最终数据的semaphore
 - v. master卡等待其他卡计算完成的semaphore
 - vi. master卡将自己卡上的 $1/m$ 数据通过brpc依次发给其余 $m-1$ 台机器（异步rpc调用，在rpc内部会将数据拷贝到share_memory, 并且post 多机的信号量）
 - vii. master等待其他机器都数据发过来的信号量，然后通知本机其他卡的信号量
8. 将数据拷贝到各个卡上；
9. 通知主线程，当前all_reduce已经完成；

2.3 昆仑一多机多卡需要额外的初始化工作

根据2.2的多机多卡的流程，相比于单机多卡，需要的额外初始化工作包括：

1. 需要知道有多少机器，以及当前机器有多少卡，并且确定当前机器都master卡的rank
2. 需要有其余各个机器brpc的地址，方便给其他机器发送数据；
3. 需要在本地机器起一个rpc服务，方便接收其他机器都数据
4. 有 m 个内存buffer，用于存放其他卡发送过来的数据
5. 有一个多机的信号量，用来保证收到了其他机器的数据
6. 有一个多机的信号量，用来保证收到了其他机器计算后的数据
7. 每张卡有一个信号，可以开始拷贝数据到卡上
8. 给每个rank一个local rank id
9. 使用之前分配的buffer和semaphore来同步信息

