

T4晋升

目录

- 成长点说明
- 技术影响力
- 工程能力
- 技术治理
- 项目信息

成长点说明

i 如下成长点说明：请在此部分总结自上一次晋升以来个人在技术上的主要成长点及其体现：每个成长点请用<=200字概述，对应工作中体现可通过提供项目材料，设计文档，报告等材料作为支撑，可以附件形式提供，注明对应关系即可，总字数2000以内。（变化说明：为了提高申请表的填写质量，加快评定效率。请大家务必认真填写此部分内容，突出要点，切勿只是简单材料罗列。此部分是职称评定的首要依据，未来访谈或述职不是缺省都发起，只在评委会认为有必要的时候才发起，因此请务必重视此栏目填写质量）

1、技术能力范围扩展，健全技术视野

作为校招生，在短时间内承担组内交接工作，负责Paddle-Lite推理框架ARM移动端方向OP/kernel开发以及性能优化(汇编级别)工作，完成了Q3&Q4的Benchmark项目既定目标，在PP系列模型上实现了性能领先&&追平竞品。

在推理部署方面，昆仑XPU之前主要通过Paddle-Lite框架进行应用落地，随着昆仑 XPU在厂内的大规模使用，而Paddle-Inference中却没有太多针对昆仑XPU的优化，性能无法满足业务的要求。积极参与了Paddle主框架Inference XPU方向的框架升级工作，并参与了车载昆仑芯项目，构建了从移动端到服务端的推理方向技术能力。

2、技术规划能力

在深度学习中，推理侧有大量的性能分析与优化的需求，而Paddle Lite框架正面临着手机设备多样化、手机芯片更新速度快、模型优化周期长，当前Profiler性能信息有限等问题，因此在积累了一定的优化经验后，开始着手对框架的Profiler工具制定了三步走的升级规划：

第一阶段，调研不同竞品中的性能分析工具，引入了RoofLine Model对模型优化的一般步骤进行抽象化建模，从模型层面和算子层面收集模型的各种性能数据，做到用户对底层硬件无感知，收

敛了模型优化的需求入口，只需提供Profiler输出日志即可迅速分析定位模型性能问题；

第二阶段，对当前Profiler架构进行分层升级，先添加新增的性能信息，再对内部统计接口进行升级，不影响日常开发工作的同时做到“无感”升级；

第三阶段，进行易用性提升工作（文档、一键启动脚本），减少外部用户使用的成本，同时也减轻了业务模型性能需求的复现工作。分阶段规划和落地，同时组织对组内的技术分享，做到“可依赖”。

技术影响力

- i** 请填写下面方面内容，并附参考材料（上传附件），限定2000字以内。 1、做的模块、平台在公司的影响力，比如影响了多少个产品 2、BIT讲课次数以及发表内刊文章次数 3、外部会议邀请报告次数 4、发表论文篇数

【业务影响】

Paddle Lite ARM CPU方向工作，作为核心开发者，面对复杂的硬件环境，坚持软硬件端到端优化思路，追求优化方法的通用性，当前Paddle-Lite ARM CPU端侧性能在业界领先，支持了厂内手百、如流等多条重要产品线。

【技术分享与沉淀】

团队内部技术分享：

《端侧高性能优化方法-基于Roofline模型》

《ARM NEON技术分享》

跨部门技术分享：

《XTCL知识分享：PaddleLite 在Conv和GEMM利用cache分块优化》

工程能力

- i** 工程能力是技术型企业最核心的竞争力，是产品和业务成败的关键影响因素，也是衡量工程师能力的重要指标。如在工程能力建设和研发效能提升方面（含持续提升研发效率、研发质量等），以及产品意识、客户意识和安全意识方面有突出贡献，请在此处举证说明，需说明研发效率改进方面的关键举措、效果和横向影响力（效果上请直接参考并引用工程效能评估体系中的客观指标，如人（月）均交付需求数量及研发交付周期、需求交付周期等）。针对工程能力方面的具体要求详见：<https://ku.baidu-int.com/d/Pth0jJci3lsirb>，针对工程效能评估体系相关指标请参考：<https://console.cloud.baidu-int.com/devops/ireport/insight/effectiveness>。

(1) 编码能力

严格遵守编码规范提高代码可阅读性。

(2) 质量意识

严格遵守研发规范和流程。

(3) 项目管理

在团队经历变动的情况下，与另一个同事合理规划，高质完成了Benchmark的优化工作。

项目执行中，有较强的综合职业素养：

- 风险识别应对能力：在开发过程中，及时更新进度，将风险及时暴露出来。
- 整体工作规划能力：根据业务支持优先级，对细分的工作能够制定出合理的方案与分工。

(4) 需求把握

能准备把握需求进行技术方案选型，且对技术方案有较好的自主判断能力，同时能着眼当前项目整体情况考虑成本。在项目的前期，多沟通，精确把握需求，减轻后期压力，并能制定合理的排期，保障提供较优的性能优化方案。

(5) 产品意识

以产品化的思维打磨负责的开源项目，从代码接口设计，演示demo、说明文档等，有较全面的思考，在完成功能的同时，考虑功能的通用性、易用性，尽量提供易用的脚本或工具，促进外部用户使用，扩大repo社区影响力。在开发工作中，养成调研竞品的习惯，注重发掘核心用户的需求，养成打造产品差异化能力的意识。

(6) 客户意识

在业务对接中，有较好的客户意识，能从业务历史的角度出发，理解客户痛点和需求，提供解决问题的思路或方法。

技术治理

 为了综合评价对技术复用、技术先进性等领域的思考和所具有能力，请举证所参与的技术治理相关工作及具体效果，包括但不限于研发技术栈收敛（收敛编程语言、编程框架、开发工具等）、研发公共环境升级、Paddle推广覆盖、平台化建设、全栈上云（云原生进阶、业务上云等）等相关工作。

项目信息

 【项目名称】 移动端深度学习框架Benchmark建设

【所在公司】 百度内

【项目时间】 2022-07-18 - 2022-12-31

【承担角色】 核心开发者

【专业能力】 C++/ARM CPU/性能优化

【业务方向】 高性能计算

【项目描述】 搭建Paddle-Lite与竞品对比的Benchmark框架，包括FP32、FP16、INT8等多种精度，覆盖检查、分类、分割、NLP等多场景常见模型，建立周级别Benchmark流水线。

【项目职责】 搭建 Paddle-Lite 及竞品测试环境，优化PP系列套件模型、常用开源模型等共计52个模型，23个INT量化模型，在ARM CPU端性能持平或赶超竞品。

【项目成员】 马健平（接口人&核心开发者）、汪子奇（核心开发者）、肖稳（QA）

【角色分工】

- 马健平：搭建 Paddle-Lite 及竞品测试环境，优化52个FP16精度模型、23个INT8量化模型在主流Android平台上的性能，协助FastDeploy集成Paddle-Lite。
- 汪子奇：搭建 Paddle-Lite 及竞品测试环境，优化52个FP16精度模型在主流Android平台(骁龙865、888等)上的推理性能，目标打平&&领先竞品。
- 肖稳：QA验证优化成果，搭建周级别Benchmark pipeline。

【项目业绩】

完成模型优化预设目标。具体工作如下：

- FP16精度模型性能达到既定目标，领先&打平竞品。
- 调研竞品（MNN）几何计算差异化特性，输出技术文档组内分享。
- 针对depthwise_conv，实现通用优化，在常见shape下性能显著提升。
- 针对复杂的卷积计算，引入Google Benchmark工具统计不同shape下的性能情况，梳理当前框架中的卷积实现策略，为后续优化提供指导并输出技术文档组内分享。

 【项目名称】 Paddle+XPU萝卜快跑项目（进行中）

【所在公司】 百度内

【项目时间】 2023-03-01 - 2023-05-15

【承担角色】

【专业能力】 C++/硬件适配/性能优化

【业务方向】 AI硬件适配优化

【项目描述】

IDG萝卜快跑业务感知、PNC和定位场景中存在较多模型仍使用竞品框架训练和推理，没有切到Paddle体系内，计划将44个模型迁移到Paddle+XPU生态中，Paddle-Inference 目前没有太多针对昆仑XPU 的优化，性能问题紧迫。

【项目职责】

Paddle+XPU生态下，迁移适配44个IDG萝卜快跑业务模型，且性能达到预定目标，支撑车载昆仑系统集成。

【项目成员】

陈泽裕（项目负责人）、洪明（接口人&技术负责人）、朱鹏阳（核心开发者）、江帆（接口人&核心开发人员）、汪子奇（核心开发者）、陈思宇（核心开发者）、逯甜甜（核心开发者）、王俊杰（X2Paddle）、刘续东（QA）、昆仑团队、IDG自动驾驶团队

【角色分工】

- 洪明：项目负责人
- 朱鹏阳：增加所需的框架特性
- 江帆：支持车机系统集成，模型测试工具
- 陈思宇：负责pnc、定位模型的精度对齐和性能
- 汪子奇（本人）：负责27个感知模型的精度对齐以及14个重点模型的优化
- 逯甜甜：负责14个重点模型的优化
- 王俊杰：onnx模型转化为paddle模型
- 刘续东：搭建daily CI，提供日编译库

【项目业绩】

【项目预期收益】

1. 推动业务侧将竞品框架替换成Paddle框架的进程
2. 支撑车载昆仑芯项目

 【项目名称】 Paddle-Lite框架移动端Profiler升级

【所在公司】 百度内

【项目时间】 2023-01-01 - 2023-03-01

【承担角色】 核心开发者

【专业能力】 C++/高性能计算

【业务方向】 高性能计算

【项目描述】 在深度学习中，推理侧常有大量的性能分析与优化的需求，而Paddle-Lite框架移动端面临着手机设备多样化、手机芯片更新速度快、模型优化周期长，当前Profiler日志输出性能信息有限等问题，为了解决这些痛点，计划升级已有Profiler工具，提供功能完整且高效易用的移动端性能分析工具。

【项目职责】

覆盖升级现有Profiler功能，引入RoofLine Model收敛移动端模型性能优化的分析方法。

【项目成员】

李琦（项目负责人）、汪子奇（方案设计&核心开发者）、闫宏艳（QA）

【项目业绩】

- 增加一键式脚本工具，增加Profiler工具易用性。
- 解决Profiler编译库引入的模型推理时间增加问题，提升模型性能优化效率。
- 精简Profiler日志信息，补充高阶性能数据，降低性能优化需求的对齐难度。
- 引入RoofLine Model分析方法，扩展了模型&OP层面的移动端模型性能优化视角，并输出技术文档组内分享。



【项目名称】 Inference 适配昆仑 XPU

【所在公司】 百度内

【项目时间】 2023-01-01 - 2023-05-08

【承担角色】 开发者

【专业能力】 C++/硬件适配/性能优化

【业务方向】 Paddle Inference 硬件适配优化

【项目描述】 昆仑芯 XPU 已实现两代通用AI芯片产品的量产，在厂内包括搜索在内的多业务中都有落地应用。在训练方面，Paddle 已经对昆仑XPU 的做了长期的支持，能覆盖多个领域的主流模型。在推理部署方面，昆仑 XPU 主要通过 Paddle-Lite 框架进行应用落地，而 Paddle-Inference 没有太多对昆仑XPU 的优化，性能无法满足要求。然后，随着大模型的发展，逐渐对推理提出来更多的要求，比如分布式多卡推理，Paddle-Inference 在这方面会有更大的优势。同时，随着昆仑 XPU 训练能力增强，用户对于直接使用 Paddle 进行推理的需求也增多，完善 Paddle-Inference 昆仑 XPU 推理能带给用户更好的体验。

【项目职责】

向厂内外业务提供Paddle-Inference+AI硬件加速方案，完成项目上线，实现AI硬件在业务侧落地和适配方案的不断打磨。

【项目成员】

朱鹏阳（技术负责人）、洪明（接口人&技术指导人）、陈思宇（华为昇腾NPU方向核心开发者）、谌檀越（华为昇腾NPU核心开发人员）、paddlehw团队、昆仑团队、业务方算法同学（VIS）

【角色分工】：

- 洪明：项目负责人
- 朱鹏阳：技术负责人。
- 谌檀越：分布式推理开发
- paddlehw团队（陈思宇，江帆，汪子奇，逯甜甜）：优化支持模型，优化pass和算子接入

【项目业绩】

1. 完成昆仑XPU优化 pass 和自定义算子方案设计，支持 fp16 模型的转换和推理
2. 完成昆仑XPU大算子kernel和融合pass开发，解决大模型中共享weight的问题，精度和性能达标

3. 开源ernie系列模型精度和性能达标
4. 支持搜索和凤巢业务模型，支持萝卜快跑业务