

飞桨



转正答辩

李振宇 AI与数据平台部

Mentor: 邓凯鹏

2022-1-12



CONTENT

目录

- 01 个人简介
- 02 试用期目标达成情况
- 03 主要工作汇报
- 04 其他工作
- 05 总结与展望



01

个人简介



个人简介

paddle 飞桨

个人信息

01

姓名：李振宇

年龄：24

家乡：河南省信阳市

工作经历

03

2018.6 - 2018.8

华为技术有限公司

岗位：研发工程师

教育经历

02

- 本科 西安电子科技大学 2015.9 - 2019.7
计算机科学与技术学院-软件工程
- 硕士 西安交通大学 2019.9 - 2022.7
电信学部-软件工程

职级

04

02

试用期目标达成进展



试用期目标达成情况

- 目标1: NLP大模型业务支持, 支持业务部署上线, 降本增效。
 1. AI辅助代码生成业务ERNIE-BASE模型优化, 推理加速40%, 显存优化35%, 精度对齐, 支撑业务上线。
 2. 大模型动态输出能力建设, 大模型大词表推理优化。
 3. 文心ERNIE3.0业务支持, 加速PrefixCache、RoPE等场景, 并帮助业务同学迁移到V100机器。
- 目标2: PaddleFleetX推理建设, 重点支持GPT/ERNIE模型。
 1. 支持一站式工具FleetX开源建设, 支持GPT/ERNIE大模型部署易用且高性能, 打通单卡/多卡/FP32/FP16全流程。
 2. GPT重点大模型性能在多场景下领先最优竞品FasterTransformer。
- 目标3: 通用Transformer建设。
 1. 调研各类Transformer的相同点和不同点, 思考通用Transformer实现方式。
 2. 调研Transformer的变长实现, 并使Paddle原生FusedMultiTransformer支持变长推理。
- 目标4: 个人发展与组织建设
 1. 学习百度文化并融入团队。
 2. 深入理解Paddle及PaddleInference架构。
 3. 熟悉Paddle开发流程, 向Paddle框架贡献10+PR。
 4. 完成新人串讲。

03

主要工作汇报



背景

1. AI辅助代码生成

主要应用于在编码过程中根据输入的代码生成可能的补全代码，功能上类似于常规的代码补全。

对实时性要求比较高，采用的是1.5b的模型，业务测试耗时为500ms左右，推理加速对提升用户体验的影响很大。

2. 大模型动态输出能力建设，大模型大词表推理优化

在NLP生成模型运行过程中，往往需要解码完成后才能拿到最后的生成结果，这会影响用户体验，因此业务提出希望在解码过程中，同一批次内的不同请求可以采用不同的k值、p值，且可以实时拿到中间结果。

通过使用大词表降低大模型的解码长度，可以提升大模型推理速度，业务预期可减少30%的解码长度，但在词表很大时解码阶段的速度较慢，因此业务同学提出需要优化大词表下的解码性能。

3. 文心ERNIE3.0业务

NLP同学在ERNIE3.0上持续优化，很多优化点在FusedMultiTransformer中不支持，因此无法享受融合Kernel的加速效果，因此需要根据ERNIE3.0的新特性在FusedMultiTransformer上进行相应的实现，以强化推理性能。




AI辅助代码生成

1. FusedMultiTransformer支持post_layer_norm。

使FusedMultiTransformer支持post_layer_norm的网络结构，并成功接入业务代码中。 [PR44789](#)

2. 安全算子支持，支持第一层不融合使用安全算子，剩余层使用融合Kernel的形式。



3. Cache KV支持动态设置大小，降低显存占用。

使Cache KV可以根据输入长度和最大解码长度动态地设置大小，相比于硬编码方式进一步降低了显存占用。 [PR46777](#)



大模型业务支持

AI辅助代码生成 收益

在A100，FP16场景下测试

速度上，在batch_size为5时加速比为**1.91**，在batch_size为10时加速比为**1.83**。

batch_size	优化前耗时(ms)	优化后耗时(ms)	加速比
5	507.966	265.254	1.91
10	619.843	338.6	1.83

显存上，在batch_size为1、5、10时分别**降低35.75%、34.6%和35%**。

batch_size	优化前(GB)	优化后(GB)	降低(%)
1	4	2.57	35.75
5	4	2.616	34.6
10	4.1	2.665	35

业务同学反馈已上线，性能提升一倍，每日补全数量在**6w+**次。



大模型动态输出能力建设，大模型大词表推理优化。

1. 自定义算子save_output_op维护

在颜卉转团队后根据业务需要对自定义算子save_output_op进行维护。解决线上部署遇到的问题。

2. paddle.topk性能优化

通过降低同步次数、优化启动配置和补数策略等方式优化Paddle中KeMatrixTopK的性能，在大词表场景下性能提升2~4倍。 [PR45312](#)

3. paddle.softmax性能优化

通过向量化等方式优化Paddle中softmax的性能，在大词表场景下性能提升2~6倍， [PR46535](#)

4. 实现自定义算子TopPSampling

Paddle原生中的采样过程在CPU上进行，比较耗时，因此实现了自定义算子TopPSampling。

该方案已广泛应用（PaddleFleetX、文心业务）。

申请专利：一种自适应排序的大模型TopP采样加速优化方法（已递交专利局）



大模型动态输出能力建设，大模型大词表推理优化。 收益

1. 动态输出功能上线后第一周日均访问量**增加115%**。
2. 大模型大词表推理优化，使得在大词表场景下30w词表较3w词表慢最低**降至2.9%**，加速比最大可达**4.8**。

batch_size	模型-词表	优化前耗时(ms)	相对慢值(%)	优化后耗时(ms)	相对慢值(%)	加速比
1	0.1B-3w	0.140230		0.132064		1.06
1	0.1B-30w	0.441184	214.61	0.171885	30.15	2.56
1	1.5B-3w	0.411759		0.388383		1.06
1	1.5B-30w	0.825596	100.5%	0.399706	2.9	2.06
64	0.1B-3w	0.242441		0.176099		1.37
64	0.1B-30w	1.739491	617.49%	0.362173	105.66	4.80
64	1.5B-3w	0.650757		0.585288		1.11
64	1.5B-30w	2.089655	221.111%	0.727968	24.37	2.87



大模型业务支持

文心ERNIE3.0功能增强。

1. PrefixCache支持

使FusedMultiTransformer支持PrefixCache，业务已上线。 [PR46777](#)

2. 解决了PrefixCache较大时（400M）的数据传输时延问题。

a. 使用FP16传输数据

b. 多卡分布式传输后all_gather

c. 消除CPU拷贝

3. RoPE编码支持

使FusedMultiTransformer支持RoPE编码，支持业务上线，使理论最大解码长度可以无限增大。 [PR48842](#)

4. V100机器迁移


a. V100报错问题

b. 相同输入不通batch_size输出结果不同

c. 相同输入相同模型不同设备输出不同

5. 敏感词屏蔽自定义算子实现

分别在CPU和GPU上实现了敏感词屏蔽自定义算子ngram_mask_op，在GPU上通过数组方式模拟前缀树缩小搜索空间，将敏感词屏蔽的时延控制在0.1ms以下。





文心ERNIE3.0功能增强。 收益

1. 使机器部署成本降低80%： 由80张40G A100+200张80G A100 降低为 16张40G A100+40张80G A100。
2. 推理速度在千亿模型batch_size为4时提升309.58%(3.6713 -> 1.1859)。
3. RoPE编码支持，在端到端小说生成业务上，结果可用率10%->16%，生成5500字小说耗时由10分钟降低为2分钟，性能提升五倍。
4. 线上访问量，12月与9月相比日均调用量提升60.46%，日均调用用户数提升143.46%。

9月	ERNIE 3.0 Zeus
日均调用量	48371
日均调用用户数	4006

12月日均	ERNIE 3.0 Zeus
日均调用量	77618
日均调用用户数	9753



总体业务收益

飞桨 PaddlePaddle

NLP大模型

代码生成

batch_size为5、10时加速比分别为**1.91**和**1.83**，提速接近一倍。

batch_size为1、5、10时分别**降低35.75%、34.6%和35%**。

已上线，每日补全次数在**6w+**次。

大模型大词表

动态输出功能上线后第一周日均**访问量增加115%**。

大词表场景下30w词表较3w词表慢**最低降至2.9%**，加速比最大可达**4.8**。

文心ERNIE3.0

机器部署**成本降低80%**：由80张40G A100+200张80G A100 降低为 16张40G A100+40张80G A100。

常规业务推理速度在千亿模型batch_size为4时**提升309.58%**(3.6713 -> 1.1859)。

在端到端小说生成业务上，结果**可用率10%->16%**，生成5500字小说耗时由10分钟降低为2分钟，**性能提升五倍**。

线上访问量，12月与9月相比日均调用量**提升60.46%**，日均调用用户数**提升143.46%**。



心得

1. 依托业务支持搞懂算法、弄懂源码、熟悉框架、学习优化。
2. 支持的功能上线且有收益，才是有意义的。
3. 沟通能力很重要。

反思

1. 需要持续加强沟通能力，加强自我驱动力。
2. 对框架源码理解不够深入，虽然查看了不少框架代码，但因为缺少实际需求而缺乏深刻理解，后续需要加强。
3. 对Paddle中的分布式实现理解不深，需要加强。

背景

PaddleFleetX旨在打造一套简单易用、性能领先、且功能强大的端到端大模型工具库。我们团队主要负责推理阶段。


GPT/ERNIE推理流程打通

打通GPT/ERNIE 单卡/多卡/FP32/FP16推理流程。

1. 实现多卡split qkv融合pass，使ERNIE可以走进FusedMultiTransformer。 [PR49383](#)
2. 使InferEngine支持普通导出的推理模型和自动切分导出的推理模型。 [PR959](#)
3. 增加ERNIE Inference推理脚本及文档。 [PR960](#)、[PR978](#)

GPT性能优化

1. 跨团队协作（推理、分布式、模型），优化GPT组网逻辑，消除动转静产生的同步操作，添加高性能自定义融合算子。 [PR906](#)



背景

PaddleFleetX旨在打造一套简单易用、性能领先、且功能强大的端到端大模型工具库。我们团队主要负责推理阶段。


GPT/ERNIE推理流程打通

打通GPT/ERNIE 单卡/多卡/FP32/FP16推理流程。

1. 实现多卡split qkv融合pass，使ERNIE可以走进FusedMultiTransformer。 [PR49383](#)
2. 使InferEngine支持普通导出的推理模型和自动切分导出的推理模型。 [PR959](#)
3. 增加ERNIE Inference推理脚本及文档。 [PR960](#)、[PR978](#)


GPT性能优化

1. 跨团队协作（推理、分布式、模型），优化GPT组网逻辑，消除动转静产生的同步操作，添加高性能自定义融合算子。 [PR906](#)



GPT性能优化

2. 使用Tensor Core优化FusedMultiTransformer中MMHA的性能。 [PR48087](#)



最终在345m、6.7b、175b模型下领先最优竞品FasterTransformer 3%-7% ([GPT性能数据](#))。

心得

1. 易用且高性能很有意义但不容易。
2. 要同时有信心和执行力。
3. 跨团队协作能力很重要。


反思

1. 必须更加重视文档建设，更加注意开发流程的规范性，切记不可混淆分支。
2. 需要持续加强性能优化能力，对于一个Kernel能够根据GPU型号信息及Kernel特性量化出优化前后的理论提升率。
3. 需要熟练掌握Nsight Compute工具，弄清楚其中每个部分的含义并根据该信息进行对应的优化。

背景

在业务支持及FleetX建设的过程中，发现Paddle中为了支持不同的模型有多套transformer的实现，且对于NLP生成模型常用的FusedMultiTransformer并不支持变长推理，所以建设通用且高性能的Transformer，并支持变长推理的功能。

1. 调研了各类Transformer的相同点和不同点，详细查看了cutlass下的高性能MemoryEfficient Attention，并与TensorRT闭源的FlashAttention进行对比，通过Nsight Compute分析了不同sequence length下MemoryEfficient Attention的性能瓶颈。
2. 调研了FasterTransformer中的GPT模型变长推理方案，并使Paddle原生FusedMultiTransformer支持变长推理。[PR49560](#)



心得

1. 总结归纳，尽可能让支持的功能更加通用。（通用高性能Transformer)
2. 全方面的考虑，首先进行完善的方案设计再进行代码开发。
3. 多看多学，吸收不同框架中的优秀设计方案。

反思

1. 在收到一个业务需求时，不要急于实现，需要全方面的考虑并进行方案设计与评审。
2. 需进一步加深对cutlass的理解，在cutlass中FMHA的基础上进一步优化性能，并做的更加通用。（支持更多不同的transformer结构)

04

其他工作



Kernel优化和功能增强

1. PFCC算子性能优化, 优化SeluKernel。 [PR44490](#)
2. 使affine_grid_op在CPU和GPU上支持5D输入。 [PR45012](#)

卡片Bug解决

1. mask_rcnn_r50_fpn_1x_coco_bs2_fp16训练报错问题排查。 ([DLTP-58063](#))
2. TIPC模型测试, ssdlite_mobilenet_v1_300_coco_upload与picodet_s_320_coco_lcnet_upload trt fp16 推理精度问题排查。 ([DLTP-56014](#), [DLTP-56016](#))
3. PPYOLOE+在Paddle-develop下TRT速度异常问题排查。 ([DLTP-58006](#))

CI迁移A10单测报错解决

test_trt_conv_pass、test_trt_deformable_conv、test_fc_elementwise_layernorm_fuse_pass、test_trt_slice_plugin、test_trt_subgraph_pass

其他业务

1. ERNIE-KIT在Paddle2.3.2下FP16报错解决。
2. ERNIE显存优化验证协助。
3. 凤巢观星业务支持。

05

总结与展望



总结

在试用期期间，主要依托于业务支持对模型、框架、性能优化手段都有了较深的理解与实践，主要做了以下工作：

1. 大模型相关业务支持，对FusedMultiTransformer进行性能优化及功能增强，支持业务上线。
2. PaddleFleetX中GPT/ERNIE推理全流程打通，GPT模型性能优化，超越最优竞品FasterTransformer。
3. 通用高性能Transformer调研，FusedMultiTransformer变长推理支持。

展望

1. 大模型业务持续支持调优，保持ERNIE/GPT大模型推理性能多场景领先性。
2. 通用且高性能的Paddle原生FMHA，期望在大多数场景下持平或超过TensorRT闭源实现。
3. Transformer类模型通用优化，a. 增强FusedMultiTransformer Encoder性能，使得在绝大多数场景下都可以通过FusedMultiTransformer进行性能优化；b. 拆分FusedMultiTransformer，降低融合粒度，灵活支持各类业务模型。
4. 分布式、深度学习编译器等技术持续学习，持续提升自己的性能优化技术水平。